

时空数据与神经网络相关文献阅读总结

袁铭潮

1 时空数据

1.1 时空数据的特点

时空数据是同时具有时间和空间维度的数据，根据维基百科的数据，现实世界中的数据超过百分之八十与地理位置有关。伴随着计算机技术的发展，如何利用计算机模拟和表征客观世界和人类活动，无疑也提供了广阔的研究空间。

时空数据由于其所在空间的空间实体和空间现象在时间、空间和属性三个方面的固有特征，呈现出多维、语义、时空动态关联的复杂性，因此，需要研究时空数据多维关联描述的形式化表达、关联关系动态建模与多尺度关联分析方法，时空数据协同计算与重构提供快速、准确的面向任务的关联约束。

时空数据包含的特点如下：

- (1)、时空数据包含队形、过程、事件在空间、时间、语义等方面的关联关系。
- (2)、时空数据具有时变、空变、动态、多维演化特点，时空变化是可度量的，变化过程可作为事件来描述，通过对象、过程与事件的关联因设，建立时空大数据的动态关联模型。
- (3)、时空数据具有尺度特性，可建立时空演化关联关系的尺度选择机制，针对不同尺度的时空演化，实现对象、过程、事件关联关系的尺度转换与重建，进而实现时空数据的多尺度关联分析。
- (4)、对关联约束可进行面向任务的分类分级，建立面向任务的关联约束选择、重构与更新机制，根据关联约束之间的相关性，可建立面向任务的关联约束启发式生成方式。
- (5)、时空数据具有时间和空间维度上的特点，实时的抽取阶段行为特征，以及参考时空关联约束建立态势模型，实时地理解和预测导致某特定阶段行为发生的态势。

时空数据存在多种类型，根据不同类型的时空数据有不同的处理方式。时空数据主要分为以下几类：

- (1)、数值型序列：即传统意义上下一的时间序列，构成元素是数值型的，如小区车辆流通的历史数据等。
- (2)、事务型序列：构成元素是事务型的。
- (3)、事件型序列：即序列的构成元素是事件。

这里使用上述分类的原因在于数据存储于数据库中，于是也沿用了数据库中对于事务和事件的区分。

时空数据目前的处理方式还是以将时间特性和空间特性分开考虑为主，分别发现基于空间和基于时间的知识。

1.2 时空数据处理及知识类型

时空数据往往带有缺失、不一致性和噪声，为了提高时空数据后续计算的效率和结果的质量，需要对时空数据进行预处理。常用预处理技术有数据清洗、数据合成、数据变换和数据消减等^[1]。

(1)、数据清洗技术主要用于处理缺失问题。在数据清洗时通过桶分、聚类 and 回归等技术可识别异常点以平滑除噪，还可以处理不一致性数据。

(2)、数据合成主要用于融合从多个数据源抽出的数据。

(3)、数据变换的目的是使变换后的数据更适于进行数据挖掘。常用技术有平滑、聚集、概括化、正规化和特征组建等。其中正规化方法较常用，主要包括最小-最大正规化、零均值正规化和小数尺度正规化。

(4)、数据消减即去除数据集中相对目标而言冗余的信息。主要包括数据立方聚集、维数消减、数据压缩和数量消减等。

针对时空数据的特点，时空数据可发现的主要知识类型在很大程度上与空间数据可发现的知识类型类似，主要不同在于时态相关性，主要包括时空分布规律、时空关联规则、时空聚类规则、时空特征规则和时空演变规则。

1.3 时空数据应用领域和发展趋势

时空数据的应用领域主要分为以下三类：

第一类是环境与交通领域，也是目前应用较为广泛的，也是目前深度学习与时空数据结合研究较多的方向。

环境方面主要与地理数据相关，例如对地球物理数据中时空模式的知识发现，地震活动结构关系的知识发现。

交通方面应用的优势在于目前数据量的优势，交通方面的时空数据的快速增长，使得深度学习在交通上的应用越来越多。最主要的应用是智能交通系统，通过对时空数据的分析，预测交通流量进行交通调度管控等等，是智慧城市系统的重要组成部分。还有基于交通数据展开的对流量的预测，客流、人流等等，对客运等行业有着深远的意义。也有以车辆为对象的时空数据，从车辆对象的估计数据中抽取车辆运动模式，预测交通堵塞、提供备选线路等。在阅读的论文中，这部分的应用是最为广泛的，预测乘车需求、预测共享单车需求等等。

第二类是基于位置的服务，目前这类应用的主要数据源还是GIS数据，可能获取自客户的分享，或者服务提供商，主要还是以带有时间标签的位置信息为主。

基于时间位置数据，当前的研究热点和主要应用有两方面，一是包括服务类型的时空邻近关系和满足某种准则的热点区域的预测发现。二是研究移动用户的时空行为模型，对用户时空行为进行描述，用户模型包括短期、中期和长期的用户信息。其中短期信息指当前的位置及最近的时空趋势，中期信息指随时间变化的用户偏好，长期信息指用户长期的变化不大的信息。通过对用户时空行为的建模，进而应用到各种不同的需求中。

第三类归为其他类型，目前主要的还是对人体运动时空模式的建模，通过对轨迹信息的建模分析，提取不为人知的运动模式，实现异常运动模式的检测或实时的动作预测。

在时空数据领域目前还有很多问题存在，特别是与深度学习相结合的交叉应用上，比如对海量的、动态增长的时空数据的有效处理，或者对不精确和变精确时空数据及运动约束条件的处理，又

或者是对面向移动环境的时空数据的处理等等。也正是为了解决这些问题，目前的主要研究热点和发展方向主要有：

- 1、复杂数据源和数据类型的处理，包括更大型的数据库、更高的维数和属性之间的更复杂的关系。
- 2、多种类型的输入数据。
- 3、用户参与和领域知识，这是于目前研究较为契合的，知识图谱和时空数据的结合很有前景，会在多种应用领域上起到推进作用。
- 4、知识的表示和解释机制，这主要还是知识图谱的研究。
- 5、知识的维护和更新。
- 6、时空数据处理算法的有效性、伸缩性与可测性。
- 7、与其他系统的集成。

2 深度学习与时空数据结合

根据前文中应用领域的分类，时空数据在深度学习上的研究应用也以交通预测、基于位置的服务以及其他类型划分，本节将以这三个分类为基础，将阅读过的相关论文进行分类总结。

2.1 交通预测

随着计算机技术的发展，近年来，许多国家都在大力发展构建智慧城市，智慧城市的一大重要组成部分就是智能交通系统。智能交通系统的目标是依靠人工智能等技术实现有效的交通管理。

在这个目标的基础上，交通预测是不可或缺的一部分，如果可以事先进行准确的交通预测，对交通管理部门以及许多现实应用都至关重要。

交通预测是时空预测问题，时空预测问题在传统的数据挖掘等领域是老大难的问题，多年发展并未取得突破性的进展。得益于与交通相关的数据集的不断增长及其在现实应用中的影响，与正在蓬勃发展的深度学习相得益彰，以前很难解决的问题随着深度学习的发展正在被一点点克服。

例如交通流量预测可以帮助交通部门更好的管理和控制交通，以缓解交通拥堵。出租车需求预测可以帮助出租车公司更好的分配车辆。共享交通工具需求预测可以帮助服务公司进行资源调度。

2.1.1 交通流量预测

流量预测问题在早期的研究中是基于时序的，主要的方法是差分整合移动平均自回归模型（ARIMA）和卡尔曼滤波，分别研究每个位置的交通时间序列。最近的研究开始考虑空间信息和外部上下文信息，但是仍然基于传统的时间序列模型和机器学习模型，无法很好地捕捉复杂的非线性时空依赖性。

如何探索非线性和复杂空间数据以发现其固有的时空模型并进行准确的交通流预测是目前深度学习在交通流预测领域的主要挑战。随着深度学习在交通预测领域的研究，逐渐有了些许成果，例如将全市交通量建模为热图图像，并使用CNN建模非线性空间相关性，使用基于RNN的框架建模非线性时间相关性，并进一步提出了整合CNN和LSTM来联合对空间和时间相关性进行建模的方法。

AAAI的两篇论文对这以领域尚且存在的问题做了各自的研究。

其一是从动态空间依赖性和长周期性依赖的转移出发，在这两点上提出自己的交通流量预测模型，延续了已经成功的CNN+LSTM的组合处理空间和短期时间依赖性。

使用CNN捕获空间依赖性，通过权重共享来处理结构相似性，但不能完全反映目标区域与其邻近区域之间的关系。于是设计了一个流量门控机制用于捕获层次结构中的动态空间依赖性，分别对区域之间的流量的方向和大小分别使用CNN以捕获区域间的动态相似性，再以逐元素乘积的方式结合，经过全连接层输出到下一部分^[2]。

在上述基础上通过LSTM来获取短期的时间依赖性，以及通过attention机制对历史数据中的特征进行提取，原因在于交通数据还是呈现周期性的。

对于这一个方法，在捕获空间的动态相似性方面使用的是CNN，而CNN的天然局限性欧几里德空间，较为复杂的交通情况并不适用。

在另一篇北京交通大学的论文中^[3]，也对类似问题提出了他们的模型，基于注意力的时空图卷积模型。他们对数据的处理是将时空交通流量数据看作是时序的一帧帧的图，定义了ST模块，先分别使用时间attention和空间attention分别自适应的捕获图中的时间特征和空间特征，再使用GCN和CNN获取空间依存关系和时间依存关系，分别是空间维的GCN，从邻域捕获空间依存关系，以及沿时间维度的CNN，利用附近时间的空间依存关系。

多个ST模块之间用残差网络的方式加深网络深度，在整体上同样关注了历史周期性数据，分别对当前、前一天、前一周对应日期的数据分别进行多个堆叠ST模块处理，最后将得到的三部分用全连接层连接在得到一个输出。

这样的处理方式的好处在于能够对摆脱CNN的局限性，使用图结构能够兼容几乎所有的交通情况。但最后的处理却十分的粗糙，若是使用attention机制是不是能更好的捕获历史周期性方面的相关性，而不是固定时间段的数据固定的权重。

总体来看，两个模型采用的方法是大同小异的，虽然使用的网络模块甚至数据处理都不同，但在核心的时空特征提取上，都是将两者分开处理。在动态的空间依赖性问题上，后者并未提及，前者强行构造出一种模式来处理，说服力不强。

在不考虑算力等客观因素的情况下，目前似乎并没有很好的解决方案同时对时空特征进行提取处理得到动态相关性，这也是深度学习应用在时空数据上最大的问题之一。

2.1.2 交通需求预测

需求预测与流量预测的本质区别在于数据的不同，需求预测的数据是基于带有时间戳和地理信息的个人的历史数据，周期性依赖不强，因此与目前的交通流量预测的方法大体上是不同的。

在港科大和南加大合作发表的一篇乘车需求预测的论文中，使用了channel-wise attention，为每个通道学习一个权重，以便找到最重要的帧并赋予更高的权重来强调，这与前文中提到的基于注意力的时空图卷积模型的手工部分可以尝试用通道注意力机制进行优化。

这篇文中还提出了另一汇总基于图的编码方式，使用多个图对区域之间关系的不同方面进行编码^[4]，包括邻域、功能相似性和运输连接性，尚且不能断定这两种图编码方式那一种更有效，但都有各自的可取指出。

在时间相关性建模的处理上，这篇文章定义了一种上下文关联的RNN，但总归是基于RNN的，在时间序列的处理上还是不如LSTM来的更好，个人认为类似的仅在时间序列的处理建模还是使

用LSTM效果更好，在后文为提到类似的完全基于LSTM的变体模型。最后还是采用了GCN来进行处理，不过因为不像前一篇文章中的需要使用GCN来提取时间相关性，所以采用了更为高效的频域GCN中的ChebNet。

同样一篇由北京交通大学发表的论文着眼于共享单车的需求预测^[5]，定义了事件流序列化的方式将动态异构图的演变进行编码，以此完成对动态图的潜在和空间敏感的演化过程的信息提取。后续使用attention机制对事件流序列化编码的节点进行重要性采样。

相较于其他模型的不同之处在于将时空图转换为向量，并结合来自天气、时间、地理位置和历史转变模式的多元信息输入到LSTM中进行时间建模。

其优点在于结合了多源异构信息，通过向量的方式统一编码。若是在不使用向量的情况下该如何类似多源信息进行结合呢？

根据当前的研究现状，时间建模方面还是以LSTM为主，CNN因为其局限性以及GCN的发展，图结构还是优先级最高的数据表示方式，历史周期性上通道注意力机制表现较好。

根据阅读过的论文稍微提出点个人的想法，使用图结构并通过GCN提取动态空间相关性，再结合LSTM进行时间建模，总体使用通道注意力机制控制，结合上述论文的长处，是否能够得到更好的效果？

2.2 基于位置的服务

这部分的论文就偏少的，主要的数据是带有时间和位置标签的签到数据，类似于带时空标签的社交网络数据等。与深度学习密切相关的主要是基于时间和位置的推荐系统。

对于深度学习来说，数据是发展的一大推动，近年来基于位置的社交网络服务快速增长。这些服务已经吸引了许多用户分享他们的位置和体验，并积累了大量标记数据。这些在线足迹或签到数据提供了了解用户移动行为的绝佳机会。

这方面的论文比较少看到，对于近期的一些研究成果如HST-LSTM、ST-RNN之类并没有太多了解，仅从看过的这一篇论文出发，提出了一种STGN的模型^[6]。模型本身并不复杂，在LSTM的基础上增加了时间门控和距离门控，以捕获签到之间的时空间隔距离，很好地同时建模用户的短期和长期兴趣。

这类模型的关键在于其精妙的设计，本身并没又十分具有开创性的地方。

倒是这篇论文中提到的一些研究成果值得更深入的阅读，就不赘述了。

另一部分个人认为也能划分这一领域的是对轨迹的建模，包括整体轨迹和个体轨迹。

比如一篇由日本NTT通讯实验室发表的论文，对人口流量进行了估计^[7]，但是由于计算代价的问题，并没有对个体进行计算，通过对区域过渡人口数量的过渡概率通过神经网络进行建模，并且仅使用了三层前馈神经网络，最后使用极大似然和正则化约束条件来估算。

又比如菜鸟公司的用于估计包裹到达时间的模型，对每个包裹的递送路径进行建模^[8]。

与使用one-hot或卷积层表示地理位置的传统方式不同，首先根据地理位置进行编码，然后将其嵌入短向量中。结合传递路径中每个节点的传递状态，用LSTM提取路径的顺序特征。

设计了两个基于注意力的模块来学习历史性频繁和相对交货路线。为了解决RNN无法学习大量历史数据之间的相关性的问题，先提取相对传递路径并利用注意力机制找到最相似的路径，同时考虑已交付和未交付的包裹来丰富模型。

与前文类似，使用的还是在时间建模上较为出色的LSTM，为了使用LSTM对地理闻之进行编码嵌入向量。但是并没有采用类似残差网络的方式来实现，确号称是DeepETA，这里ETA表示估算包裹达到时间。这个Deep是怎么来的文章中确并没有给出解释，而LSTM和RNN是典型的浅层神经网络模块。

基于位置的应用还是很少，在后续研究中可以阅读这类文章借鉴方法和思路，实际应用上局限性太大。

2.3 其他类型

除去上述的应用之外，还有的是对人体运动时空模式的建模，通过对轨迹信息的建模分析，提取不为人知的运动模式，实现异常运动模式的检测或实时的动作预测。

输入的数据是视频或连续的图，对人体运动模式进行预测。目前这类问题看到的研究都是基于相同的数据集的，即NTU-RGB+D和Kinetics，基于骨骼的人体动作识别将3d人体坐标作为输入，输出动作类别。这类问题在现实生活中随着摄像头的增多，应用范围也越来越广。

这方面的论文目前看到过两篇，第一篇提出了ST-GCN的模型^[9]，将每一帧中的人体骨骼关节看作一个图，将视频按时序展开，构成一个三维的图。在这个三维的图上使用基于空域的GCN提取时空特征，没有考虑连接边的情况，但是总体效果很好。ST-GCN也被很多论文用来作为baseline进行比较。

另一片论文是在ST-GCN的基础上，对ST-GCN存在的一些问题进行了进一步的解决。通过时空图路由方案STGR^[10]，开发骨架关节之间固有的高阶关系，更好的匹配动作识别任务。

空间图路由是对每一帧骨架使用非参数化的图聚类分割方法并组合得到每一帧的空间连接图，收集所有图形成空间图池，在使用注意力机制进行建模，选择信息量最大的图作为代表。

时间图路由则先使用LSTM对每个节点进行编码，然后以self-attention的方式对每个节点建立关系模型。

最后将得到的均输入到ST-GCN中，得到的效果比ST-GCN要更好。

在论文分析中类比引入了图的感受野，证明了STGR有效的扩大了每个关节的感受野，所以得到的效果更好。

这方面的应用看似与时空数据关系不大，但可以预见的应用是结合人物重识别ReID任务即可得到固定地理位置带有时间戳的海量数据，这些数据在前文的各类应用中都是能够起到很好效果的。

个人认为，通过视频数据结合运动模式预测将是今后时空数据应用落地十分关键的一环，也是具有极大潜力的一个方向。

3 对于时空数据的一些想法

3.1 与知识图谱的结合

知识图谱与时空数据相结合是一个很有前景的发展方向，特别是与领域知识相结合，能够充分发挥知识图谱本身的辅助性能。

当前基于时空数据的深度学习和知识图谱的研究几乎没有，也是一个能够出成果的方向。

对于两者的结合，目前个人的想法有三个。

一是结合轨迹信息实现轨迹预测，借助知识图谱的帮助强化类别区分和预测准确度。通过速度等信息判断交通工具类别，结合周遭地标辅助判断目的地，实时交通信息判断拥堵情况等形式，达到较高精度的轨迹预测。

二是结合PIO信息和个人访问历史，借助知识图谱达到更为精确的PIO推荐。

三是动作识别方面，通过分析视频中所处环境达到辅助进行动作预测的目的。

以上是基于时空数据的三大应用领域与知识图谱相结合的一点想法。

由于对与知识图谱用于辅助推理的神经网络了解不多，需要对这方面做相关调研以论证其可行性。

3.2 一些不成熟的想法

本来是没有这一小节的，原因在于今年年初的新型冠状病毒的疫情，由于新型冠状病毒人传人的特性，被隔离并进行医学观察的人员均是确诊病例密切接触过的，这里存在的问题是对同行程人员的判断和密切接触者的界定。

与时空数据相关的是，能否在已知有限的公共行程的基础上，以受感染者为标签，对潜在的可能接触者进行界定是否存在感染可能，以达到辅助确认需要隔离人员的功能。

甚至考虑是否可以借此次疫情，尝试维护一个行程数据库。

参考文献

- [1] 赵彬彬, 李光强, 邓敏. 时空数据挖掘综述[J]. 测绘科学(2):22+64-67.
- [2] Yao H , Tang X , Wei H , et al. Revisiting Spatial-Temporal Similarity: A Deep Learning Framework for Traffic Prediction[J]. 2019.
- [3] Shengnan Guo , Youfang Lin , Ning Feng , et al. Attention Based Spatial-Temporal Graph Convolutional Networks for Traffic Flow Forecasting[J]. 2019.
- [4] Xu Geng , Yaguang Li , Leye Wang , et al. Spatiotemporal Multi-Graph Convolution Network for Ride-hailing Demand Forecasting[J]. 2019.
- [5] Youru Li , Zhenfeng Zhu , Deqiang Kong , et al. Learning Heterogeneous Spatial-Temporal Representation for Bike-Sharing Demand Prediction[J]. 2019.
- [6] Zhao P , Zhu H , Liu Y , et al. Where to Go Next: A Spatio-temporal LSTM model for Next POI Recommendation[J]. 2019.
- [7] Tomoharu Iwata , Hitoshi Shimizu. Neural Collective Graphical Models for Estimating Spatio-temporal Population Flow from Aggregated Data[J]. 2019.
- [8] Fan Wu , Lixia Wu. DeepETA: A Spatial-Temporal Sequential Neural Network Model for Estimating Time of Arrival in Package Delivery System[J]. 2019.

- [9] Yan S , Xiong Y , Lin D . Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition[J]. 2018.
- [10] Bin Li , Xi Li , Zhongfei Zhang , et al. Spatio-Temporal Graph Routing for Skeleton-Based Action Recognition[J]. 2019.